

Pràctica 3: Anàlisi d'Algoritmes d'Aprenentatge per Reforç Multiagent JAL-GT en l'entorn POGEMA

SID - Grup 03

Enric Segarra

Marc Font

Pablo Calomardo

12 de juny de 2025

Índex

1	Introducció	3
2	Descripció de l'entorn POGEMA	4
2.1	Característiques de l'entorn	4
2.2	Components de l'observació	4
2.3	Conversió d'observacions a estats	4
3	Metodologia experimental	5
3.1	Hipòtesis principals	5
3.2	Paràmetres d'experimentació	5
3.3	Mètriques d'avaluació	6
4	Algoritmes estudiats	7
4.1	Joint Action Learning with Game Theory (JAL-GT)	7
4.1.1	Fonaments teòrics	7
4.1.2	Conceptes de solució implementats	7
4.1.3	Fortaleses i debilitats teòriques	7
4.2	Independent Q-Learning (IQL)	8
4.2.1	Fonaments teòrics i implementació	8
4.2.2	Avantatges i limitacions	8
5	Resultats experimentals	9
5.1	Experiment 1: Optimització de paràmetres i convergència	9
5.2	Experiment 2: Efecte dels conceptes de solució segons el tipus d'entorn	10
5.3	Experiment 3: Coordinació entre agents amb conceptes diferents	11
5.4	Experiment 4: Comparació JAL-GT versus Independent Q-Learning	11
5.5	Experiment 5: Escalabilitat i convergència	12
5.6	Experiment 6: Generalització a mapes no vistos	12
6	Discussió i anàlisi	14
6.1	Verificació sistemàtica d'hipòtesis	14
6.2	Implicacions dels resultats	15
6.3	Comparació amb la literatura	15
7	Conclusions i recomanacions	16
7.1	Conclusions principals	16
7.2	Recomanacions pràctiques	16
7.3	Limitacions de l'estudi i treball futur	16
7.4	Impacte i aplicabilitat	17
8	Referències	17

1 Introducció

En aquesta pràctica s'ha realitzat l'anàlisi i experimentació de l'algoritme Joint Action Learning with Game Theory (JAL-GT) en l'entorn multiagent POGEMA (Partially-Observable Grid Environment for Multiple Agents). L'objectiu principal ha estat estudiar el comportament d'aquest algoritme d'aprenentatge per reforç multiagent sota diferents parametritzacions i conceptes de solució.

JAL-GT representa una extensió de Q-Learning per a entorns multiagent, on l'estat pot ser una observació parcial i l'acció és una acció conjunta. Els valors Q s'utilitzen per construir conceptualment una matriu de recompenses sobre la qual es poden aplicar solucions de concepte com Minimax, equilibri de Nash, eficiència de Pareto o benestar social.

Aquest document presenta els resultats obtinguts i l'anàlisi comparativa de diferents configuracions, contextualitzant cada resultat amb les propietats teòriques dels algoritmes d'aprenentatge per reforç multiagent.

2 Descripció de l'entorn POGEMA

POGEMA és un entorn bidimensional multiagent amb observabilitat parcial dissenyat per estudiar la coordinació entre agents en entorns complexos.

2.1 Característiques de l'entorn

L'entorn POGEMA presenta les següents característiques fonamentals:

Estructura espacial: L'entorn està representat per una quadrícula amb una amplada i una alçada determinades. El perímetre del mapa està format per obstacles que delimiten l'espai de moviment dels agents. Addicionalment, poden existir obstacles aleatoris distribuïts per la quadrícula segons una probabilitat determinada per la llavor de generació.

Agents i objectius: Els agents comencen en posicions aleatòries i tenen assignat un objectiu específic que han d'assolir. Cada agent desapareix de l'entorn quan arriba al seu objectiu corresponent, rebent una recompensa de valor 1. La recompensa total de l'entorn correspon al nombre d'agents que han assolit els seus objectius.

Dinàmica d'execució: L'execució és paral·lela i no per torns, és a dir, tots els agents reben les seves observacions i decideixen les seves accions simultàniament. En cas de conflicte d'ocupació de posicions, l'agent amb identificador més petit té prioritat.

Observabilitat parcial: Cada agent té un radi d'observació limitat que determina la informació disponible sobre l'entorn. L'observació consisteix en una quadrícula de mida $(2r + 1) \times (2r + 1)$ centrada en la posició de l'agent.

2.2 Components de l'observació

Cada agent rep tres matrius que conformen la seva observació:

Matriu d'obstacles: Conté un valor de 1 si hi ha un obstacle en cada posició de la quadrícula d'observació, 0 en cas contrari.

Matriu d'agents: Indica amb un valor de 1 la presència d'agents en cada posició (incloent l'agent que rep l'observació).

Matriu d'objectiu: Presenta un únic valor de 1 a la posició de la quadrícula més propera a l'objectiu específic de l'agent. No es mostren objectius d'altres agents.

2.3 Conversió d'observacions a estats

Per poder aplicar algoritmes basats en funcions de valor discretes, les observacions complexes s'han de convertir en estats discrets mitjançant la funció `obs_to_state`. Aquesta conversió permet mantenir la informació essencial per a la presa de decisions tot simplificant l'espai d'estats per fer factible l'experimentació.

3 Metodologia experimental

3.1 Hipòtesis principals

Abans de realitzar els experiments, hem plantejat les següents hipòtesis sobre el comportament de JAL-GT en l'entorn POGEMA:

Hipòtesi 1: Els conceptes de solució cooperatius (benestar social i òptim de Pareto) produiran millors recompenses col·lectives que els conceptes competitiu (Minimax) en entorns on els objectius dels agents no són directament conflictius.

Hipòtesi 2: L'equilibri de Nash proporcionarà un comportament equilibrat entre cooperació i competició, donant resultats intermedis en termes de recompensa individual i col·lectiva.

Hipòtesi 3: JAL-GT mostrarà millor rendiment que Independent Q-Learning (IQL) en situacions que requereixen coordinació explícita entre agents.

Hipòtesi 4: A mesura que augmenti la complexitat de l'entorn (mida, nombre d'agents, obstacles), l'avantatge de JAL-GT respecte a IQL es farà més evident.

Hipòtesi 5: L'algoritme mostrarà capacitats de generalització limitades quan s'avalui en mapes no vistos durant l'entrenament, especialment si la distribució d'obstacles és significativament diferent.

3.2 Paràmetres d'experimentació

Per avaluar el comportament de JAL-GT, hem considerat els següents paràmetres i els seus rangs de valors:

Paràmetres de l'entorn:

- Mida de l'entorn: $[2 \times 2, 3 \times 3, 4 \times 4, 6 \times 6, 8 \times 8]$
- Nombre d'agents: $[2, 3, 4]$
- Probabilitat d'obstacles: $[0.1, 0.2, 0.3]$
- Radi d'observació: $[1, 2]$

Paràmetres de l'algoritme:

- Factor de descompte (γ): $[0.9, 0.95, 0.99]$
- Taxa d'aprenentatge (α): $[0.1, 0.3, 0.5]$
- Coeficient d'exploració inicial (ϵ): $[1.0, 0.8]$
- Factor de decaïment d'epsilon: $[0.995, 0.999]$
- Nombre d'episodis d'entrenament: $[500, 1000, 2000]$

Conceptes de solució:

- Minimax
- Equilibri de Nash (mixt)
- Benestar social (welfare)
- Òptim de Pareto

3.3 Mètriques d'avaluació

Per mesurar el rendiment dels diferents experiments, utilitzarem les següents mètriques:

Eficiència d'entrenament:

- Temps d'entrenament per episodi
- Temps d'entrenament total
- Nombre d'episodis necessaris per a la convergència

Qualitat de les polítiques:

- Recompensa individual mitjana per agent
- Recompensa col·lectiva total
- Taxa d'èxit (percentatge d'agents que arriben al seu objectiu)
- Optimalitat de la trajectòria (comparació amb el camí òptim teòric)

Capacitat de generalització:

- Rendiment en mapes no vistos durant l'entrenament
- Robustesa davant de canvis en la distribució d'obstacles
- Adaptabilitat a diferents nombres d'agents

4 Algoritmes estudiats

4.1 Joint Action Learning with Game Theory (JAL-GT)

JAL-GT és un algoritme d'aprenentatge per reforç multiagent que estén Q-Learning per tractar amb accions conjuntes i aplicar conceptes de solució de la teoria de jocs.

4.1.1 Fonaments teòrics

L'algoritme JAL-GT es basa en la representació de la interacció multiagent com un joc repetit on, a cada pas temporal, els agents han de coordinar les seves accions per maximitzar les seves recompenses individuals o col·lectives segons el concepte de solució escollit.

La funció Q en JAL-GT es defineix com:

$$Q_i(s, \vec{a}) = Q_i(s, a_1, a_2, \dots, a_n) \quad (1)$$

on s és l'estat actual, $\vec{a}$ és el vector d'accions conjuntes, i Q_i representa la funció valor-acció per a l'agent i .

L'actualització de la funció Q segueix la fórmula estàndard de Q-Learning adaptada per a accions conjuntes:

$$Q_i(s, \vec{a}) \leftarrow Q_i(s, \vec{a}) + \alpha [r_i + \gamma V_i(s') - Q_i(s, \vec{a})] \quad (2)$$

La diferència clau respecte a Q-Learning estàndard radica en el càlcul de $V_i(s')$, que es determina aplicant el concepte de solució escollit sobre la matriu de pagaments construïda a partir dels valors Q .

4.1.2 Conceptes de solució implementats

Cada concepte de solució proporciona una manera diferent d'interpretar la interacció estratègica entre agents:

Minimax: Cada agent assumeix que els altres agents actuaran per minimitzar la seva recompensa, adoptant una estratègia defensiva que maximitza la recompensa mínima garantida.

Equilibri de Nash: Els agents busquen una combinació d'estratègies on cap agent pot millorar unilateralment canviant la seva estratègia, representant un punt d'estabilitat estratègica.

Benestar social (Welfare): Els agents cooperen per maximitzar la suma total de recompenses, prioritzant l'eficiència col·lectiva sobre els interessos individuals.

Òptim de Pareto: Els agents busquen solucions on no és possible millorar la recompensa d'un agent sense empitjorar la d'un altre, garantint eficiència en el sentit de Pareto.

4.1.3 Fortaleses i debilitats teòriques

Fortaleses:

- Consideració explícita d'interaccions estratègiques

- Flexibilitat en objectius de coordinació mitjançant diferents conceptes de solució
- Base teòrica sòlida en la teoria de jocs

Limitacions:

- Complexitat computacional exponencial amb el nombre d'agents
- Dependència de l'observabilitat completa de les accions
- Rigidesa en la representació d'estats (taules Q)

4.2 Independent Q-Learning (IQL)

Per establir una línia base comparativa rigorosa i comprendre els avantatges específics de la coordinació explícita en JAL-GT, hem implementat Independent Q-Learning com a punt de referència.

4.2.1 Fonaments teòrics i implementació

Independent Q-Learning adopta una perspectiva simplificada dels entorns multiagent, tractant cada agent com si operés en un entorn estacionari. Aquesta aproximació ignora deliberadament la presència d'altres agents durant el procés d'aprenentatge, aplicant l'actualització estàndard de Q-Learning:

$$Q_i(s, a_i) \leftarrow Q_i(s, a_i) + \alpha \left[r_i + \gamma \max_{a'_i} Q_i(s', a'_i) - Q_i(s, a_i) \right] \quad (3)$$

La diferència fonamental respecte a JAL-GT radica en que IQL utilitza només l'acció individual de cada agent (a_i) en lloc del vector d'accions conjuntes ($\vec{a}$).

4.2.2 Avantatges i limitacions

Avantatges:

- Simplicitat computacional i facilitat d'implementació
- Escalabilitat lineal respecte al nombre d'agents
- Possibilitat de paral·lelització trivial de l'entrenament

Limitacions:

- Incapacitat per capturar dependències estratègiques entre agents
- Violació de l'assumpció d'estacionarietat de l'entorn
- Impossibilitat d'aprendre estratègies de coordinació explícites

5 Resultats experimentals

Per avaluar de manera rigorosa el comportament de JAL-GT i comparar-lo amb alternatives, hem dissenyat sis experiments específics que exploren diferents aspectes del rendiment de l'algoritme.

5.1 Experiment 1: Optimització de paràmetres i convergència

L'experiment 1 s'ha centrat en identificar les configuracions de paràmetres que promouen la millor convergència tant en termes de recompensa com d'eficiència computacional. S'han variat sistemàticament el nombre d'agents, la mida del mapa, la densitat d'obstacles i la taxa d'aprenentatge.




Figura 1: Evolució de la recompensa col·lectiva en configuració simple (pocs agents, baixa densitat d'obstacles).




Figura 2: Evolució de la recompensa col·lectiva en configuració complexa (molts agents i obstacles).

Els resultats mostren una clara correlació inversa entre la complexitat de l'entorn i la capacitat de convergència de l'algoritme. Com s'observa a la Figura 1, les configuracions amb pocs agents i baixa densitat d'obstacles permeten que la recompensa col·lectiva arribi ràpidament a valors propers al nombre total d'agents (aproximadament 2). En contrast, la Figura 2 revela que les configuracions complexes presenten una convergència notablement degradada.




Figura 3: Evolució de l'error de diferència temporal segons la complexitat de l'entorn.




Figura 4: Temps d'entrenament per episodi en configuracions complexes.

L'anàlisi de l'error de diferència temporal (Figura 3) confirma aquesta tendència, mostrant que l'algoritme aprèn més eficientment en entorns menys complexos. La Figura 4 evidencia que el temps d'entrenament augmenta dramàticament amb la complexitat.

Els millors resultats experimentals s'obtenen amb taxes d'aprenentatge moderades (0.1), pocs obstacles i pocs agents. En canvi, configuracions amb molts agents i obstacles donen recompenses baixes i convergència lenta o nul·la. Per maximitzar la convergència i la recompensa cal escollir paràmetres que no facin el problema massa complex.

5.2 Experiment 2: Efecte dels conceptes de solució segons el tipus d'entorn

Aquest experiment examina com diferents conceptes de solució influencien el comportament dels agents en tres tipus d'entorns: interessos comuns (cooperatius), conflictius (competitius) i mixtos.




Figura 5: Rendiment dels conceptes de solució en entorns d'interessos comuns.




Figura 6: Rendiment dels conceptes de solució en entorns conflictius.

Els resultats revelen patrons comportamentals clarament diferenciats segons el concepte de solució utilitzat. A la Figura 5 es veu que Welfare i Pareto aconseguir recompenses excepcionals, arribant fins a valors propers a 2 en entorns cooperatius amb fluctuacions que indiquen exploració efectiva. Contràriament, a la Figura 6, Minimax i Nash mantenen un rendiment més estable i robust, mentre que Welfare i Pareto mostren un rendiment considerablement degradat en aquests entorns adversarials.

L'anàlisi de robustesa (Figura 7) mostra que Nash manté un rendiment consistent independentment de la taxa d'aprenentatge utilitzada ($lr=0.01$, $lr=0.05$, $lr=0.1$), posicionant-se com el concepte més equilibrat i estable.

El concepte òptim depèn clarament de l'entorn: Welfare/Pareto són excel·lents per a cooperació, però fracassen en conflicte. Minimax/Nash són més robustos en entorns difícils. Experimentalment, Nash és el més equilibrat i estable.




Figura 7: Robustesa de Nash davant variacions en la taxa d'aprenentatge.

5.3 Experiment 3: Coordinació entre agents amb conceptes diferents

S'han entrenat parells d'agents, cadascun amb un concepte de solució diferent, generant animacions de la seva coordinació per comparar trajectòries i recompenses.

Les observacions qualitatives de les animacions SVG generades mostren patrons interessants:

- A les animacions Nash vs Welfare es veu una coordinació fluida
- A les animacions Minimax vs Pareto els agents sovint bloquegen el camí de l'altre i no arriben a l'objectiu
- Les combinacions Nash vs Nash i Welfare vs Welfare són les que mostren més èxit i coordinació

Els agents poden coordinar-se parcialment si els conceptes són compatibles (Nash/Welfare), però la manca d'alineació (Minimax vs Pareto) porta a estratègies subòptimes i fracàs en la tasca. La política d'un agent pot limitar la recompensa de l'altre, com es veu clarament a les animacions on un agent prioritza la seva pròpia estratègia.

5.4 Experiment 4: Comparació JAL-GT versus Independent Q-Learning

S'ha executat una comparativa robusta entre JAL-GT (Nash) i IQL, entrenant amb diverses llavors per recollir mètriques de recompensa, error TD i estadístiques de Q.

A la Figura 8 es veu que JAL-GT (línia taronja) aconsegueix una recompensa mitjana superior i més estable que IQL (línia blava) a través de múltiples llavors d'experimentació. A la Figura 9, l'error TD de JAL-GT disminueix més ràpid i es manté més estable que IQL. A la Figura 10, JAL-GT mostra menor variabilitat en els valors Q màxims, indicant una major consistència en l'aprenentatge.

JAL-GT és més robust i estable que IQL, especialment en entorns amb interacció estratègica. Experimentalment, JAL-GT aconsegueix millors recompenses i menor variabilitat. IQL pot tenir més variabilitat i menor rendiment en escenaris complexos, com es veu en la dispersió de les corbes.




Figura 8: Comparació de recompenses mitjanes entre JAL-GT i IQL.




Figura 9: Evolució de l'error TD per JAL-GT i IQL.




Figura 10: Variància dels valors Q màxims per ambdós algoritmes.

5.5 Experiment 5: Escalabilitat i convergència

S'ha avaluat la convergència de JAL-GT (Nash) variant la mida del mapa i el nombre d'agents, recollint recompenses, èxit i temps d'entrenament per cada configuració.

A la Figura 11 es veu que amb 2 agents la recompensa pot arribar fins a valors propers a 2 en mapes petits (4x4), però degrada significativament en mapes més grans (6x6, 8x8, 10x10). A la Figura 12 la taxa d'èxit decreix dràsticament amb l'augment de la mida del mapa, arribant a ser pràcticament zero en configuracions complexes.

L'algoritme escala raonablement per a pocs agents i mapes petits, però la dificultat creix ràpidament amb la complexitat. El temps d'entrenament augmenta exponencialment i la convergència esdevé inassolible en escenaris grans.

5.6 Experiment 6: Generalització a mapes no vistos

S'ha entrenat el model exloent 10 mapes del set d'entrenament. Després, s'ha avaluat el rendiment tant en mapes vistos com en no vistos.

A la Figura 13 es veu una diferència dramàtica: mentre l'entrenament (últims 10 mapes) mostra una recompensa col·lectiva propera a 0.1, el test en mapes no vistos és pràcticament zero (vermell). En contrast, el test en mapes vistos (verd) manté un rendiment alt similar a l'entrenament. A les Figures 14 i 15, la taxa d'èxit en mapes no vistos és pràcticament zero, mentre que en vistos es manté substancialment alta.

L'algoritme té dificultats severes per generalitzar a mapes no vistos: la recompensa i l'èxit cauen dràsticament. Només en mapes vistos es manté el bon rendiment. Per millorar




Figura 11: Convergència de la recompensa col·lectiva amb 2 agents en diferents mides de mapa.




Figura 12: Taxa d'èxit amb 2 agents segons la mida del mapa.

la generalització caldria entrenar amb més diversitat de mapes o aplicar tècniques de regularització. Experimentalment, la transferència d'aprenentatge és molt limitada.




Figura 13: Comparació de recompensa col·lectiva en mapes vistos vs. no vistos.



Figura 14: Taxa d'èxit en mapes vistos vs. no vistos.




Figura 15: Taxa d'èxit individual per agent.

6 Discussió i anàlisi

6.1 Verificació sistemàtica d'hipòtesis

L'experimentació realitzada ens permet avaluar de manera rigorosa les hipòtesis plantejades inicialment:

Hipòtesi 1: S'ha confirmat contundentment. Els conceptes cooperatius (Welfare i Pareto) aconseguixen rendiments excepcionals en entorns d'interessos comuns, però mostren fragilitat extrema en entorns conflictius.

Hipòtesi 2: L'equilibri de Nash ha demostrat ser efectivament el concepte més equilibrat i robust, proporcionant rendiment consistent en tots els tipus d'entorn.

Hipòtesi 3: La superioritat de JAL-GT respecte a IQL s'ha confirmat de manera clara, amb millors recompenses mitjanes, menor variabilitat i convergència més ràpida.

Hipòtesi 4: S'ha confirmat parcialment. En entorns de complexitat moderada l'avantatge de JAL-GT es fa més pronunciat, però quan la complexitat esdevé excessiva, ambdós algoritmes experimenten degradació significativa.

Hipòtesi 5: S'ha confirmat dramàticament. JAL-GT presenta dificultats severes per transferir aprenentatge a entorns no vistos durant l'entrenament.

6.2 Implicacions dels resultats

Els resultats obtinguts tenen implicacions importants per a la comprensió i aplicació d'algoritmes d'aprenentatge per reforç multiagent:

Selecció de conceptes de solució: La naturalesa de l'entorn determina críticament quin concepte de solució és més adequat. Nash emergeix com la opció més versàtil per a situacions incertes o mixtes, mentre que Welfare/Pareto són ideals per a cooperació pura.

Limitacions d'escalabilitat: Les limitacions d'escalabilitat de JAL-GT no són merament una qüestió d'implementació, sinó un obstacle fonamental que deriva de la representació tabulada de l'espai d'accions conjunes.

Necessitat d'aproximacions híbrides: Els resultats suggereixen que aplicacions pràctiques requeriran aproximacions que combinin els avantatges de JAL-GT amb tècniques que superin les seves limitacions d'escalabilitat i generalització.

6.3 Comparació amb la literatura

Els nostres resultats són consistents amb estudis previs que han identificat limitacions similars en algoritmes d'aprenentatge per reforç multiagent basats en taules. La superioritat de Nash com a concepte de solució equilibrat coincideix amb resultats teòrics que destaquen la seva robustesa estratègica.

7 Conclusions i recomanacions

7.1 Conclusions principals

Aquest estudi ha proporcionat una avaluació exhaustiva de JAL-GT en l'entorn POGEMA, revelant tant les seves capacitats com les seves limitacions fonamentals:

Eficàcia en entorns apropiats: JAL-GT demostra clara superioritat sobre IQL en entorns que requereixen coordinació, especialment quan la complexitat es manté dins de límits manejables (2-4 agents, mapes fins a 8×8).

Importància de la selecció del concepte de solució: La naturalesa de l'entorn determina críticament l'eficàcia dels diferents conceptes de solució. Nash proporciona la millor robustesa general, mentre que conceptes específics poden excel·lir en condicions particulars.

Limitacions crítiques d'escalabilitat: L'algoritme experimenta degradació severa del rendiment en entorns complexos, limitant la seva aplicabilitat pràctica.

Deficiències en generalització: La incapacitat per transferir aprenentatge a entorns no vistos representa una limitació crítica per a aplicacions del món real.

7.2 Recomanacions pràctiques

Basant-nos en l'evidència experimental, establim les següents recomanacions:

Per a la selecció de conceptes de solució:

- Utilitzar Welfare o Pareto en entorns predominantment cooperatius
- Seleccionar Nash per a entorns mixtos o incerts
- Reservar Minimax per a situacions clarament adversarials

Per a la configuració de paràmetres:

- Taxa d'aprenentatge al voltant de 0.1 per al millor equilibri convergència-estabilitat
- Factor de descompte entre 0.95-0.99 per capturar recompenses a llarg termini
- Limitar la complexitat a 3-4 agents i mapes màxim 8×8

Per a millorar la generalització:

- Entrenar amb conjunts de mapes considerablement més diversos
- Considerar tècniques de regularització
- Explorar aproximacions de funcions més expressives

7.3 Limitacions de l'estudi i treball futur

Aquest estudi presenta certes limitacions que ofereixen oportunitats per a recerca futura:

Limitacions identificades:

- Enfocament limitat a representacions tabulades
- Avaluació en un únic tipus d'entorn (POGEMA)

- Conjunt limitat de conceptes de solució explorats

Direccions prometedores per al treball futur:

- Implementació amb aproximacions de funcions neurals per superar limitacions d'escalabilitat
- Exploració d'arquitectures jeràrquiques per a coordinació multinivell
- Incorporació de comunicació explícita entre agents
- Desenvolupament de tècniques de meta-aprenentatge per millorar la generalització
- Avaluació en entorns més diversos per validar la robustesa dels resultats

7.4 Impacte i aplicabilitat

Malgrat les limitacions identificades, aquest estudi proporciona contribucions valuoses:

Contribucions teòriques:

- Quantificació precisa dels compromisos entre diferents conceptes de solució
- Establiment de límits empírics per a l'aplicabilitat de JAL-GT
- Identificació de direccions clares per a millores algorítmiques

Aplicacions potencials:

- Sistemes robòtics cooperatius en entorns controlats
- Gestió de trànsit en interseccions o zones limitades
- Coordinació de drons en missions de vigilància
- Optimització de recursos en sistemes distribuïts petits

En conclusió, aquest estudi estableix una base empírica sòlida per comprendre les capacitats i limitacions de JAL-GT, proporcionant tant insights teòrics valuosos com recomanacions pràctiques per a la seva implementació. Mentre que les limitacions identificades representen desafiaments significatius, també ofereixen direccions clares per a la recerca futura en aprenentatge per reforç multiagent.

8 Referències

1. Material de les sessions teòriques i de laboratori de SID: <https://sites.google.com/upc.edu/grau-sid>
2. Documentació de POGEMA: <https://github.com/AIRI-Institute/pogema>